SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Diplomski sveučilišni studij računarstva

IMPLEMENTACIJA ALGORITMA „FOCUS STACKING“ ZA PROŠIRENJE DUBINSKE OŠTRINE FOTOGRAFIJA

Obrada slike i računalni vid

Tamara Kaselj

Osijek, 2026.

Sadržaj

1. UVOD ... 1
2. PREGLED PODRUČJA I PROBLEMATIKE ... 2
   2.1. Povijesni kontekst i razvoj fuzije slike ... 2
   2.2. Izazovi detekcije oštrine ... 2
   2.3. Problem „disanja fokusa“ (Focus Breathing) ... 2
   2.4. Suvremeni trendovi i Deep Learning ... 3
3. KVANTIFIKACIJA LOKALNE OŠTRINE (FOCUS MEASURE) ... 4
   3.1. Detekcija rubova i visoke frekvencije ... 4
   3.2. Laplacianov operator i diskretna konvolucija ... 4
   3.3. Tenengradov gradijent (Sobelov operator) ... 5
   3.4. Visokorezolucijska piramidalna fuzija (engl. Laplacian Pyramids) ... 6
   3.5. Uloga Gaussovog filtra u suzbijanju šuma ... 6
4. NAPREDNE METODE: PORAVNANJE I DUBOKO UČENJE ... 8
   4.1. Geometrijska registracija slika (ORB I Homografija) ... 8
      4.1.1. ORB detektor (Oriented FAST and Rotated BRIEF) ... 8
      4.1.2. findHomograpy i RANSAC algoritam ... 8
      4.1.3. warpPerspective transformacija ... 9
   4.2. Fuzija temeljena na konvolucijskim neuronskim mrežama (VGG19) ... 9
      4.2.1. Arhitektura VGG19 i princip dubokog učenja ... 9
      4.2.2. Hijerarhija značajki i sloj block1_conv2 ... 9
      4.2.3. Aktivacijske mape kao mjera fokusa ... 10
5. IMPLEMENTACIJA ALGORITMA ZA FUZIJU SLIKA ... 12
   5.1. Prikupljanje i opis korištenih podataka (MFI-WHU i vlastiti dataset) ... 12
   5.2. Arhitektura sustava i predobrada slika ... 12
   5.3. Logika „Max Sharpness“ odabira i kreiranje binarne maske ... 13
   5.4. Konstrukcija kompozitne slike ... 14
   5.5. Programska implementacija algoritma ... 14
      5.5.1. Klasične metode i geometrijska registracija ... 15
      5.5.2. Duboko učenje i vizualizacija značajki (VGG19) ... 18
      5.5.3. Implementacija procesa fuzije i automatizacija ... 19
6. ANALIZA REZULTATA I EVALUACIJA ... 22
   6.1. Vizualna analiza rezultata (EDoF) ... 22
   6.2. Testiranje utjecaja parametara (Veličina kernela) ... 22
   6.3. Kvantitativna evaluacija metrikama SSIM i PSNR ... 27

6.4. Analiza artefakta i ograničenja 29
6.5. Evaluacija na vlastitom skupu podataka 30
6.6. Zaključak o evaluaciji 33
ZAKLJUČAK 35
LITERATURA 36

1. UVOD

U suvremenoj digitalnoj fotografiji i optičkom inženjerstvu, jedan od temeljnih izazova s kojim se susreću fotografi i istraživači je ograničenje dubinske oštrine (engl. *Depth of Field* – DoF). Dubinska oštrina definira se kao udaljenost između najbliže i najudaljenije točke u sceni koje se na fotografiji čine prihvatljivo oštrima. Zbog fizičkih zakona loma svjetlosti kroz sustav leća, u svakom trenutku postoji samo jedna „ravnina fokusa“ koja je savršeno oštra, dok objekti ispred ili iza te ravnine progresivno postaju zamućeni.

Ovaj problem postaje kritičan u specifičnim granama fotografije kao što su:

- Makrofotografija: Kod snimanja ekstremno malih objekata iz neposredne blizine, dubinska oštrina može biti tanka svega nekoliko milimetara, što onemogućuje prikaz cijelog subjekta (npr. kukca ili cvijeta) u fokusu.
- Pejzažna fotografija: Kada fotograf želi istovremeno zadržati oštrinu na detalju u neposrednom prvom planu i na planini u daljini.
- Mikroskopija: Gdje su numeričke aperture objektiva visoke, a dubinska oštrina gotovo zanemariva.

Kako bi se zaobišla ova optička ograničenja bez smanjenja otvora blende (što bi uzrokovalo gubitak svjetlosti i difrakciju), razvijena je tehnika *Focus Stacking* (hrv. Fuzija fokusa). To je proces digitalne obrade slike koji se temelji na spajanju serije fotografija (engl. *stack*) iste scene, gdje je svaka fotografija snimljena s blago pomaknutom točkom fokusa.

Cilj ovog rada je istražiti i implementirati algoritam koji automatski analizira takvu seriju slika, prepoznaje najoštrije regije u svakom pojedinom kadru pomoću matematičkih operatora za detekciju rubova (Laplacianov operator) te ih spaja u jednu kompozitnu sliku s proširenom dubinskom oštrinom (engl. *Extended Depth of Field* – EdoF). Kroz ovaj rad bit će prikazano kako se softverskim rješenjem mogu prevladati fizička ograničenja leća te dobiti vizualni rezultati koji su optički neostvarivi u jednom snimku.

2. PREGLED PODRUČJA I PROBLEMATIKE

2.1. Povijesni kontekst i razvoj fuzije slike

Problem fuzije slika s različitim fokusom (engl. *Multi-focus Image Fusion*) desetljećima je prisutan u računalnom vidu. Rani pristupi oslanjali su se na ručno kombiniranje dijelova fotografija u tamnim komorama, dok se u digitalnoj eri razvijaju algoritmi koji proces automatiziraju. Danas se te metode dijele u dvije glavne skupine:

1. Metode u prostornoj domeni: One koje izravno manipuliraju pikselima (poput Laplacianovog operatora).
2. Metode u frekvencijskoj domeni: Koriste transformacije poput diskretne kosinusne transformacije (DCT) ili Wavelet transformacije kako bi izolirale detalje visoke frekvencije.

2.2. Izazovi detekcije oštrine

Glavna problematika ovog područja je kako matematički definirati oštrinu. Računalo interpretira sliku kao matricu brojeva, a „oštrina“ se u digitalnom smislu prepoznaje kao prisutnost naglih promjena intenziteta na rubovima. Problem nastaje kod slika s malo teksture (npr. vedro nebo ili glatki zidovi) gdje klasični filtri ne mogu lako odrediti je li taj dio u fokusu ili ne. Tu nastupa potreba za naprednijim mjerama oštrine (engl. *Focus Measures*).

2.3. Problem „disanja fokusa“ (Focus Breathing)

U realnim uvjetima, jedan od najvećih problema je problem „disanja fokusa“ (engl. *Focus Breathing*). Prilikom promjene fokusne udaljenosti, fizička leća blago mijenja svoje povećanje (uvećanje slike). To znači da dva snimka iste scene s različitim fokusom nisu savršeno preklopljena (piksel-na-piksel). Suvremeni algoritmi pokušavaju to riješiti putem:

- Registracije slika: Automatsko geometrijsko poravnanje slika prije same fuzije.
- Naprednih metoda stapanja: Korištenje piramidalne fuzije kako bi se izbjegli vidljivi prijelazi („šavovi“) na granicama između oštrih i zamućenih područja.

2.4. Suvremeni trendovi i Deep Learning

Danas se sve više istražuju metode temeljene na dubokom učenju (engl. *Deep Learning*). Konvolucijske neuronske mreže (CNN) treniraju se na tisućama primjera kako bi naučile prepoznati dubinu i fokus bez eksplicitnih matematičkih formula. Ipak, klasične metode poput onih opisanih u ovom radu i dalje su standard u mnogim komercijalnim sustavima zbog svoje brzine, efikasnosti i činjenice da ne zahtijevaju ogromne računalne resurse.

3. KVANTIFIKACIJA LOKALNE OŠTRINE (FOCUS MEASURE)

U ovom poglavlju detaljno se obrađuje matematički i programski proces prepoznavanja oštrih dijelova slike. Kako bi računalo moglo donijeti odluku o fuziji, potrebno je svaku ulaznu sliku pretvoriti u takozvanu kartu oštrine (engl. *Focus Map*). Ovaj proces je ključan jer kvaliteta slike izravno ovisi o preciznosti ove faze.

3.1. Detekcija rubova i visoke frekvencije

Iz perspektive računalnog vida, oštrina slike nije subjektivan dojam već matematička korelacija s prisutnošću rubova. Rub predstavlja mjesto nagle promjene intenziteta piksela na malom prostoru.

Kada je objekt u fokusu, zrake svjetlosti se sijeku točno na senzoru, stvarajući jasne i oštre prijelaze između tamnih i svijetlih regija (npr. rub lista na cvijetu ili tekstura kamena). Na zamućenim dijelovima slike (izvan fokusa), te se zrake raspršuju, prijelazi postaju „razvučeni“ i glatki, što u frekvencijskoj domeni predstavlja niske frekvencije. S druge strane, oštri detalji (teksture, linije, rubovi) predstavljaju visoke frekvencije. Da bismo kvantificirali oštrinu, moramo izolirati te visoke frekvencije pomoću filtara visoke propusnosti (engl. *High-pass filters*).

Iako se za detekciju rubova često koriste operatori prvog reda poput Sobela, Laplacian je u procesu fuzije superiorniji jer je operator drugog reda. Dok Sobel detektira promjene intenziteta samo u horizontalnom ili vertikalnom smjeru, Laplacian je izotropan – jednako reagira na fine detalje i teksture u svim smjerovima, što omogućuje preciznije mapiranje regija u fokusu [1].

3.2. Laplacianov operator i diskretna konvolucija

Kao primarna metoda za detekciju rubova u ovom radu korišten je Laplacianov operator [2]. To je izotropni diferencijalni operator drugog reda koji mjeri drugu derivaciju slike u dvije dimenzije. On je izrazito osjetljiv na mjesta gdje se intenzitet naglo mijenja, što ga čini idealnim za prepoznavanje finih tekstura koje bi ljudsko oko definiralo kao „oštre“.

Matematički, za kontinuiranu sliku *I(x,y)*, Laplacian se definira kao suma parcijalnih derivacija drugog reda:

$$\Delta I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$$

Međutim, digitalna slika je diskretna (sastavljena od piksela), pa se u praksi Laplacian implementira pomoću diskretne konvolucije. To znači da program prolazi malom matricom, zvanom kernel, preko svakog piksela slike. Svaki piksel se množi s vrijednostima u kernelu, a dobiveni rezultati se zbrajaju u novu vrijednost. Najčešće korišteni kernel za ovu svrhu je:

$$L = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

Primjenom ovog kernela, regije koje imaju konstantan intenzitet (npr. plavo nebo ili glatki zid) rezultirat će nulom, dok će se na rubovima pojaviti visoke pozitivne ili negativne vrijednosti. Kako nas zanima samo postojanje ruba, a ne njegov smjer, u kodu se uzima apsolutna vrijednost rezultata (*cv2.convertScaleAbs*), čime se dobiva jasna bijela kontura na crnoj pozadini.

3.3. Tenengradov gradijent (Sobelov operator)

Uz Laplacianov operator, u radu je implementiran i Tenengradov algoritam kao alternativna mjera oštrine. Za razliku od Laplaciana koji je operator drugog reda, Tenengrad se temelji na Sobelovim operatorima prvog reda koji računaju gradijent u horizontalnom (G_x) i vertikalnom (G_y) smjeru [2].

Proračun se izvodi konvolucijom slike s parom 3x3 kernela (matrice):

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} * I, \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} * I$$

Ukupna magnituda oštrine (gradijenta) u svakom pikselu dobiva se formulom:

$$S(x, y) = \sqrt{G_x^2(x, y) + G_y^2(x, y)}$$

Tenengrad se u praksi pokazao robusnijim kod slika s izraženim linijskim teksturama jer omogućuje preciznije izoliranje rubova bez pretjeranog naglašavanja točkastog šuma. U implementiranom algoritmu, Tenengrad mapa dodatno se zaglađuje Gaussovim filtrom kako bi se osigurali kontinuirani prijelazi u finalnoj maski fuzije.

3.4. Visokorezolucijska piramidalna fuzija (engl. Laplacian Pyramids)

Kao napredna varijanta klasične detekcije rubova, u radu je implementirana i piramidalna fuzija [7]. Osnovna ideja ove metode je dekompozicija slike na različite frekvencijske pojaseve (razine rezolucije). Proces se sastoji od generiranja Gaussove piramide, gdje se slika sukcesivno smanjuje i zaglađuje, te Laplacianove piramide, koja pohranjuje detalje (razlike) između tih razina.

Prednost ovog pristupa je što se odluka o fuziji donosi na svakoj razini piramide zasebno. Time se osigurava da fini detalji budu spojeni na visokim rezolucijama, dok se šire strukture i osvjetljenje usklađuju na nižim rezolucijama, čime se drastično smanjuju vidljivi prijelazi (šavovi) u finalnoj slici.

3.5. Uloga Gaussovog filtra u suzbijanju šuma

Unatoč visokoj preciznosti u detekciji rubova, glavni nedostatak Laplacianovog operatora je njegova izrazita osjetljivost na šum u slici. Svaki digitalni senzor proizvodi određenu dozu nasumičnog šuma (zrnatosti), posebno u uvjetima slabog osvjetljenja. Laplacian će te sitne varijacije u intenzitetu interpretirati kao oštre detalje, što bi u konačnom *stacking*-procesu dovelo do „točkastih“ artefakta.

Gaussov filtar u ovom algoritmu služi kao niskopropusni filtar (engl. *low-pass filter*) [1]. Njegova je primarna zadaća ukloniti visokofrekventne varijacije koje potječu od senzorskog šuma, čime se osigurava da operatori oštrine (Laplacian i Sobel) reagiraju isključivo na stvarne bridove objekata, a ne na digitalne nepravilnosti.

Kako bi se ovaj problem neutralizirao i omogućilo napredno stapanje slika, u sustav je uveden Gaussov filtar (engl. *Gaussian Blur*). Ovaj korak „zaglađuje“ kartu oštrine koristeći Gaussovu funkciju raspodjele:

1. Smanjenje utjecaja šuma i stabilizacija (kernel 15x15): Gaussov filtar provodi operaciju konvolucije kojom se vrijednost svakog piksela korigira na temelju ponderiranog prosjeka intenziteta njegovih susjeda. U ovoj fazi koristi se kernel 15x15 kako bi se ekstremne vrijednosti šuma ublažile, a regije stvarnog fokusa stabilizirale bez pretjeranog gubitka preciznosti na rubovima.

2. Prostorna konzistentnost**:** Odluka o tome je li dio slike oštar ne donosi se izolirano za svaki piksel, već se analizira lokalno susjedstvo. To osigurava da regije koje proglasimo „oštrima“ budu veće, povezane i logičke cjeline (npr. cijela latica cvijeta ili cijelo stablo), što rezultira prirodnijim izgledom finalne slike.
3. Generiranje meke maske i Alpha Blending (kernel 31x31): Nakon donošenja binarne odluke o oštrini, primjenjuje se drugi Gaussov filtar s većim kernelom od 31x31. Ovaj korak na maski stvara gradijent, omogućujući algoritmu da na rubovima fokusa ne vrši "rez", već postepeno miješa piksele obiju slika, što rezultira prirodnijim optičkim prijelazom.

U implementaciji, korišten je veći kernel veličine 31x31 za završno stapanje kako bi se postigao optimalan balans: šum je potpuno eliminiran, a vizualni prijelazi su postali nevidljivi ljudskom oku, što je značajan napredak u odnosu na početne binarne modele. Osigurala se maksimalna glatkoća prijelaza (engl. *feathering*) na spojevima različitih ravnina fokusa.

4. NAPREDNE METODE: PORAVNANJE I DUBOKO UČENJE

4.1. Geometrijska registracija slika (ORB I Homografija)

U praksi, čak i kada koristimo stativ, promjena fokusa unutar objektiva blago mijenja vidno polje (tzv. *focus breathing*), zbog čega pikseli na istim koordinatama ne predstavljaju isti dio scene. Za rješavanje ovog problema implementiran je cjevovod (engl. *pipeline*) za registraciju slika.

4.1.1. ORB detektor (Oriented FAST and Rotated BRIEF)

Korišten je ORB algoritam kao brza i učinkovita alternativa algoritmu SIFT [3]. ORB radi u dva koraka [5]:

1. FAST (Features from Accelerated Segment Test): Pronalazi „ključne točke“ (uglove, rubove) tako što analizira krug od 16 piksela oko svakog piksela kandidata.
2. BRIEF (Binary Robust Independent Elementary Features): Svaku ključnu točku pretvara u binarni deskriptor (niz nula i jedinica), što omogućava računalu da ekstremno brzo uspoređuje točke između dvije slike.

4.1.2. findHomograpy i RANSAC algoritam

Nakon što se izvrši uparivanje deskriptora, potrebno je izračunati matricu homografije (H) dimenzija $3x3$ koja definira geometrijsku transformaciju između dvije ravnine. U OpenCV biblioteci, funkcija *cv2.findHomography* koristi kombinaciju dvije matematičke metode:

1. RANSAC (Random Sample Consensus): Budući da u procesu uparivanja točaka uvijek dolazi do pogrešaka (tzv. *outliers*), RANSAC algoritam iterativno bira minimalni broj nasumičnih parova točaka kako bi procijenio matricu. Boduje svaku procjenu na temelju toga koliko se ostalih parova točaka slaže s tim modelom [6].
2. Metoda najmanjih kvadrata (Least Squares): Nakon što RANSAC identificira skup ispravnih parova (tzv. *inliers*), OpenCV primjenjuje metodu najmanjih kvadrata na cijeli taj skup. Ova metoda minimizira sumu kvadrata udaljenosti između projiciranih i stvarnih točaka, čime se postiže maksimalna statistička stabilnost i preciznost matrice H.

4.1.3. warpPerspective transformacija

Posljednji korak poravnanja je primjena izračunate matrice na cijelu sliku. Funkcija *cv2.warpPerspective* koristi proces bilinearne interpolacije kako bi preslikala svaki piksel s izvornih koordinata na nove koordinate definirane matricom homografije. Time se ispravljaju translacija, rotacija i perspektivna izobličenja uzrokovana pomakom kamere ili *focus breathing* efektom.

4.2. Fuzija temeljena na konvolucijskim neuronskim mrežama (VGG19)

Uz klasične operatore i piramidalnu fuziju opisane u prethodnom poglavlju, implementirana je i metoda dubokog učenja koja koristi pretrenirani model VGG19 [8]. Umjesto oslanjanja na fiksne matematičke operatore (Laplace/Sobel), ovaj pristup koristi konvolucijske slojeve mreže za ekstrakciju semantičkih značajki slike. VGG19 mreža se koristi jer nudi hijerarhijsko razumijevanje značajki, dok klasični matematički operatori detektiraju isključivo naglu promjenu intenziteta piksela, VGG19 kroz svoje filtre prepoznaje složene teksture.

4.2.1. Arhitektura VGG19 i princip dubokog učenja

VGG19 je duboka konvolucijska neuronska mreža (CNN) koja se sastoji od niza konvolucijskih slojeva s malim filterima ($3x3$). U ovom radu koristi se koncept prijenosa učenja (engl. *Transfer Learning*), gdje koristima mreže trenirane na preko 14 milijuna slika (ImageNet). Umjesto klasifikacije objekata, mrežu koristimo kao ekstraktor značajki (engl. *Feature Extractor*).

4.2.2. Hijerarhija značajki i sloj block1_conv2

Neuronska mreža analizira sliku hijerarhijski. Za potrebe detekcije oštrine odabran je rani sloj block1_conv2 iz sljedećih razloga:

- Lokalne značajke: Rani slojevi reagiraju na niskorazinske značajke poput rubova, kontrasta i tekstura, što su direktni indikatori fokusa.
- Prostorna rezolucija: Budući da se nalazi na samom početku mreže, ovaj sloj zadržava visoku prostornu rezoluciju, što omogućuje precizno kreiranje maske bez gubitka detalja koji se događa u dubljim slojevima (zbog *pooling* operacija).

Eksperimentalno je utvrđeno da rani sloj block1_conv2 daje najpreciznije rezultate u očuvanju oštrih rubova. Testiranjem dubljih slojeva, poput block2_conv2 i block3_conv3, primijećeno je da značajke postaju previše apstraktne i niske rezolucije, što se može vidjeti na slici 4.1. Zbog uzastopnih slojeva sažimanja podataka (engl. *pooling*), dublji slojevi gube sposobnost preciznog definiranja finih granica, što u konačnici rezultira gubitkom preciznosti na rubovima fuzije i zamućenim prijelazima.

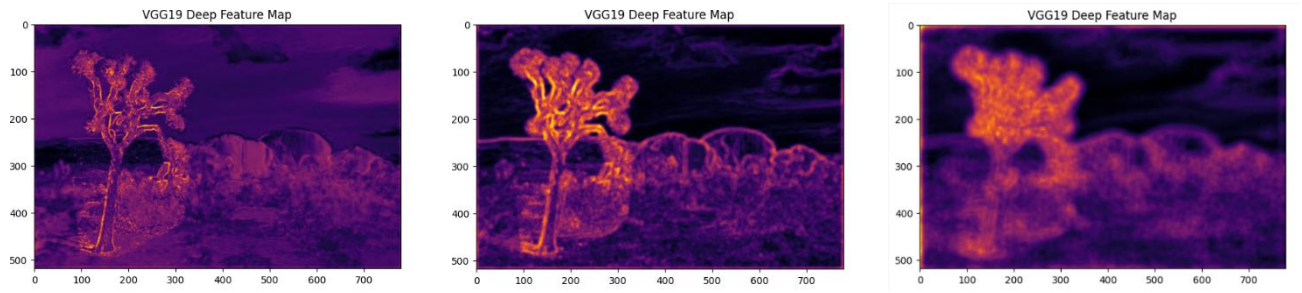

Slika 4.1. Usporedba mapa aktivacije: a) block1_conv2, b) block2_conv2, c) block3_conv3

Usporedbom mapa aktivacije (značajki) ovisno o dubini VGG19 mreže, vidimo da se povećanjem dubine sloja smanjuje gustoća informacija o rubovima te da aktivacijske mape postaju difuznije. Uočavamo da je za sloj block1_conv2 prostorna rezolucija visoka te primjećujemo precizno praćenje rubova objekata, kod sloja block2_conv2 vidimo gubitak detalja i pojavu „mrlja“ na mjestima visoke oštrine, dok se kod sloja block3_conv3 primjećuje apstraktna reprezentacija fokusa bez mogućnosti precizne lokalizacije ruba.

4.2.3. Aktivacijske mape kao mjera fokusa

Prolaskom slike kroz konvolucijske slojeve, dobiva se niz volumetrijskih podataka (aktivacijskih mapa) koji predstavljaju aktivacije neurona. Izračunom intenziteta tih aktivacija (sumiranjem kernela), generiramo toplinsku kartu (engl. *Heatmap*) koja je vizualizirana na lijevoj strani slike 4.2. Područja koja su u fokusu izazivaju snažnu reakciju neurona jer sadrže bogate vizualne informacije, visok kontrast i jasne teksture, što rezultira svijetlim (užarenim) tonovima na mapi.

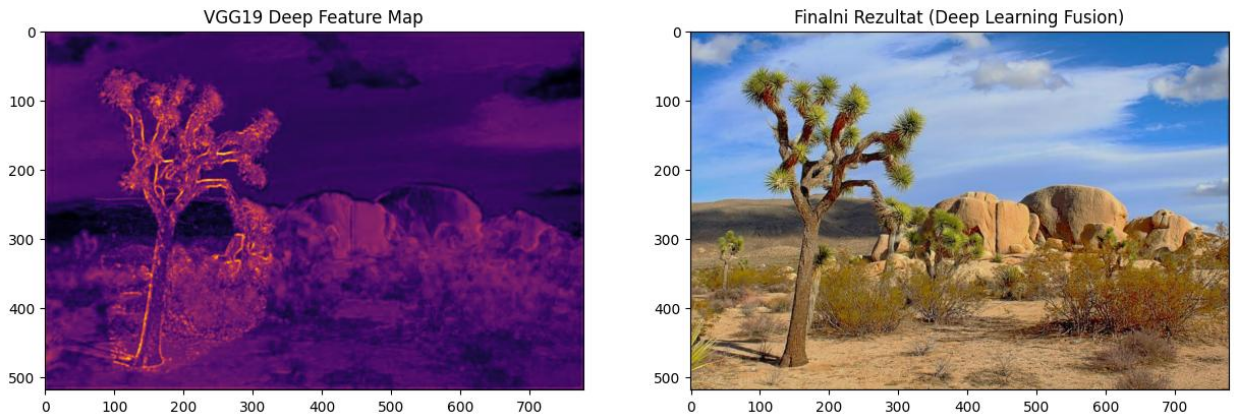

Slika 4.2. Aktivacijska mapa neuronske mreže VGG19 (lijevo) i rezultirajuća fuzija s proširenom dubinskom oštrinom (desno)

Desna strana slike 4.2. prikazuje konačnu fuziju dobivenu primjenom te AI maske. Analizom rezultata vidljive su ključne prednosti ovog pristupa u odnosu na klasične metode:

- Semantička koherentnost: Za razliku od klasičnih operatora (npr. Laplaciana) koji donose odluku na razini pojedinačnog piksela i često griješe uslijed šuma, VGG19 prepoznaje objekt kao cjelinu. Konvolucijski slojevi omogućuju mreži da prepozna strukturu predmeta, što rezultira oštrinom cijelog subjekta (npr. stabla ili predmeta na slici) bez unutrašnjih „praznina“ ili „rupa“ u fokusu.
- Čistoća rubova i preciznost granica: Zahvaljujući dubokom učenju, prijelaz između oštrog objekta u prvom planu i zamućene pozadine je znatno prirodniji. Neuronska mreža precizno definira granicu fokusa čak i kompleksnim rubovima, čime se eliminira pojava nazubljenih rubova (engl. *jagged edges*) koji su česta pojava kod primjene jednostavnih binarnih maski.
- Potiskivanje artefakata i šuma: Na završnom rezultatu vidljivo je da su pozadina i uniformne regije (poput neba ili ravnih ploha) ostale vizualno „čiste“. To je izravna posljedica robusnosti modela VGG19, koji ne reagira na digitalni šum senzora kao na informaciju o oštrini. Time je riješen jedan od glavnih nedostataka Laplacianovog operatora koji u tamnim dijelovima slike često generira lažne oštre detalje.

5. IMPLEMENTACIJA ALGORITMA ZA FUZIJU SLIKA

U ovom poglavlju detaljno je opisan praktični dio rada, uključujući opis testnih podataka, arhitekturu samog algoritma, logiku spajanja slika u jedinstvenu kompozitnu cjelinu te napredne tehnike registracije i fuzije slika.

5.1. Prikupljanje i opis korištenih podataka (MFI-WHU i vlastiti dataset)

Za razvoj i validaciju algoritma korišten je referentni znanstveni skup podataka, MFI-WHU (Multi-focus Image fusion dataset) [4], ali je sustav dodatno testiran i na vlastitom datasetu snimljenom u nekontroliranim uvjetima (snimanje iz ruke). To je zahtijevalo uvođenje dodatnog modula za geometrijsku registraciju (poravnanje) kako bi se kompenzirao pomak kamere i fenomen „*focus breathinga*“. Za razliku od kontroliranih uvjeta MFI-WHU skupa, vlastiti dataset zahtijevao je implementaciju ORB (Oriented FAST and Rotated BREIF) algoritma za geometrijsku registraciju.

Izbor MFI-WHU dataseta bio je ključan iz nekoliko razloga:

1. Kontrolirani uvjeti: Slike u ovom skupu snimljene su s fiksnih pozicija, što eliminira potrebu za prethodnom registracijom (poravnanjem) slika. Ovo omogućuje fokusiranje isključivo na kvalitetu algoritma za detekciju oštrine.
2. Raznolikost scena: Skup sadrži različite kategorije objekata – od prirodnih (lišće, cvijeće) do raznih predmeta (dijelovi kuhinje, lampa). To je omogućilo testiranje kako se Laplacianov operator ponaša na različitim teksturama.
3. Karakteristike slika: Slike su pohranjene u visokoj rezoluciji i u formatima koji zadržavaju bogatstvo detalja, što je bitno jer svaki gubitak kvalitete uslijed kompresije može stvoriti „lažne rubove“ koje bi algoritam pogrešno interpretirao.

5.2. Arhitektura sustava i predobrada slika

Sustav je implementiran u programskom jeziku Python, koristeći biblioteku OpenCV za manipulaciju slikama. Nakon inicijalne geometrijske registracije opisane u prethodnom poglavlju, proces se nastavlja pripremom podataka i ekstrakcijom informacija o oštrini.

Prije same detekcije oštrine, provodi se važan korak predobrade: pretvorba u sivu skalu (grayscale). Budući da se oštrina definira kroz promjenu intenziteta svjetline, a ne kroz samu boju, računanje nad RGB kanalima bilo bi procesorski zahtjevno i nepotrebno.

Pretvorbom u sivu skalu dobivamo matricu vrijednosti od 0 do 255 koja reprezentira luminaciju. Luminacija predstavlja komponentu digitalne slike koja nosi informaciju o intenzitetu svjetla. Budući da se ljudska percepcija oštrine primarno oslanja na varijacije u kontrastu i svjetlini, izolacija luminacije (pretvorbom u sivu skalu) omogućuje diferencijalnim operatorima da precizno detektiraju rubove bez interferencije informacija o boji. Ovaj proces značajno optimizira izračun i eliminira potencijalne pogreške u detekciji oštrine koje bi mogle nastati uslijed zasićenja pojedinih kanala boja. Iako se detekcija oštrina vrši na izoliranoj luminaciji (sivoj skali), konačna fuzija vrši se na originalnim RGB kanalima. Time se osigurava da oštrina bude precizno locirana, dok izvorni kolorit fotografije ostaje netaknut.

Na temelju pripremljene luminacije, sustav provodi hibridnu analizu:

- Laplacianov operator: Koristi se kao primarna metoda za detekciju rubova putem izračuna druge derivacije intenziteta slike.
- Tenengradov gradijent: Koristi Sobelove filtre za robusniju detekciju oštrine u uvjetima niskog kontrasta.
- Piramidalna fuzija: Temelji se na dekompoziciji slike u više razina oštrine (višerezolucijska analiza), što omogućuje preciznije stapanje kompleksnih tekstura.
- VGG19 Deep Learning: Koristi duboke slojeve mreže za generiranje toplinskih mapa (engl. *heatmaps*) koje vizualiziraju kako umjetna inteligencija interpretira fokusirane regije.

5.3. Logika „Max Sharpness“ odabira i kreiranje binarne maske

Srž algoritma čini proces odlučivanja (engl. *Decision Making*). Nakon što su za svaku ulaznu sliku generirane karte oštrine pomoću Laplaciana i Gaussovog zamućivanja, sustav stvara binarnu mapu odluke.

Logika se temelji na „pixel-wise“ usporedbi:

- Za svaki piksel na koordinati (x, y), algoritam uspoređuje vrijednost oštrine $S_1(x, y)$ iz prve slike i $S_2(x, y)$ iz druge slike.
- Ako je $S_1 > S_2$, piksel na toj lokaciji u finalnoj slici bit će preuzet iz prve izvorne slike.
- U suprotnom, piksel se preuzima iz druge izvorne slike.

Ova metoda osigurava da se u konačnom rezultatu zadrži apsolutno najoštrija informacija dostupna u cijelom nizu slika. Rezultat ovog koraka je binarna maska (crno-bijela slika) koja služi kao „karta“ za rezanje i spajanje originalnih fotografija. Međutim, sirova binarna maska često sadrži „točkasti šum“ i oštre rubove koji bi uzrokovali vidljive prijelaze na finalnoj slici.

Korištenje meke maske (engl. *Soft Mask*): Kako bi se ti nedostaci uklonili, na binarnu masku primjenjuje se dodatni Gaussov filtar s kernelom 31x31. Ovaj korak pretvara oštre prijelaze (0 i 1) u kontinuirani gradijent (vrijednost između 0 i 1). Rezultat je meka maska koja služi kao temelj za *Alpha Blending,* omogućujući prirodno pretapanje fokusa bez vidljivih šavova.

5.4. Konstrukcija kompozitne slike

Završna faza je generiranje slike s proširenom dubinskom oštrinom (engl. *Extended Depth of Field* - EDoF). Program koristi prethodno generiranu masku kako bi, umjesto grubog rezanja, proveo proces težinskog stapanja (engl. *Alpha Blending*).

Kako bi se izbjegao oštar, neprirodan „rez“ na mjestima gdje se fokus mijenja, fuzija se izvodi prema sljedećoj formuli za svaki piksel:

$$Output(x, y) = I_1(x, y) * M_{soft}(x, y) + I_2(x, y) * (1 - M_{soft}(x, y))$$

Gdje je:

- I_1, I_2 – ulazne slike s različitim ravninama fokusa.
- M_{soft} – meka maska dobivena Gaussovim zaglađivanjem (kernel 31x31).

Ovakav pristup omogućuje da se na rubovima fokusa pikseli obiju slika međusobno prožimaju. Time se dobivaju blagi prijelazi (engl. *feathering*) koji simuliraju prirodan optički pad oštrine leće, čime finalna slika izgleda kao da je snimljena jednom, idealnom optikom s beskonačnom dubinskom oštrinom. Primjena ove metode značajno smanjuje vidljivost artefakata nastalih zbog mikropomaka ili nesavršenog poravnanja, što rezultira vizualno besprijekornom kompozitnom cjelinom.

5.5. Programska implementacija algoritma

Nakon teorijskog opisa logike, u nastavku je prikazan ključni dio razvijene Python skripte koji integrira klasične metode detekcije rubova i duboko učenje (engl. *Deep Learning*) za

postizanje optimalne fuzije. Korištenjem biblioteka OpenCV i NumPy, proces fuzije je automatiziran, čime je omogućena brza obrada velikog broja slika uz zadržavanje visoke preciznosti.

5.5.1. Klasične metode i geometrijska registracija

Prije same fuzije, sustav mora osigurati da su ulazni podaci geometrijski usklađeni i da su mape oštrine stabilne. Ovaj dio implementacije fokusira se na robusnost detekcije rubova kroz dva različita matematička pristupa te na precizno poravnanje slika.

1. **Geometrijska registracija (ORB poravnanje):**

Budući da su slike iz vlastitog dataseta snimljene iz ruke, uočeni su mikropomaci koji bi bez obrade uzrokovali „*ghosting*“ artefakte (duple rubove). Funkcija *align_images* prikazana u prilogu 5.1. koristi ORB deskriptore za pronalaženje 10000 ključnih točaka na obje slike. Pomoću RANSAC algoritma izračunava se matrica homografije koja transformira drugu sliku u koordinatni sustav prve, osiguravajući savršeno poklapanje piksela.

```
def align_images(img1, img2):
    gray1 = cv2.cvtColor(img1, cv2.COLOR_BGR2GRAY)
    gray2 = cv2.cvtColor(img2, cv2.COLOR_BGR2GRAY)

    orb = cv2.ORB_create(10000)
    kp1, des1 = orb.detectAndCompute(gray1, None)
    kp2, des2 = orb.detectAndCompute(gray2, None)
    matcher=
cv2.DescriptorMatcher_create(cv2.DESCRIPTOR_MATCHER_BRUTEFORCE_HAMMING)
     matches = sorted(matcher.match(des1, des2, None), key=lambda x:
x.distance)
    good_matches = matches[:int(len(matches) * 0.15)]

   pts1=np.float32([kp1[m.queryIdx].pt for m in good_matches]).reshape(-
1, 1, 2)
          pts2    =    np.float32([kp2[m.trainIdx].pt    for    m    in
good_matches]).reshape(-1, 1, 2)
```

```
    h, _ = cv2.findHomography(pts2, pts1, cv2.RANSAC)

    return cv2.warpPerspective(img2, h, (img1.shape[1], img1.shape[0]))
```

Programski kod 5.1. Funkcija align_images

2. **Diferencijalni operatori (Laplacian i Tenengrad):**

U sustav su implementirane dvije funkcije za ekstrakciju mapa oštrine kako bi se omogućila usporedba performansi. U prilogu 5.2. prikazane su obje funkcije, prva koja koristi Laplacianov operator te druga koja koristi Tenengrad.

```
def get_laplacian_map(img):
    gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
    lap = cv2.Laplacian(gray, cv2.CV_64F, ksize=3)
    return cv2.GaussianBlur(np.absolute(lap), (15, 15), 0)

def get_tenengrad_map(img):
    gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
    sobelx = cv2.Sobel(gray, cv2.CV_64F, 1, 0, ksize=3)
    sobely = cv2.Sobel(gray, cv2.CV_64F, 0, 1, ksize=3)
    tenengrad = np.sqrt(sobelx**2 + sobely**2)
    return cv2.GaussianBlur(tenengrad, (15, 15), 0)
```

Programski kod 5.2. Funkcije za ekstrakciju mapa oštrine

3. **Višerezolucijska fuzija (Laplacian Pyramids):**

U Python implementaciji korištene su OpenCV funkcije cv2.pyrDown i cv2.pyrUp za izgradnju 6 razina piramide. Fuzija se vrši na principu maksimalnog apsolutnog odgovora na svakom nivou, nakon čega se slika rekonstruira zbrajanjem razina odozdo prema gore. Funkcija piramidalne fuzija prikazana je u prilogu 5.3.

```
def pyramid_fusion(img1, img2, levels=6):
    G1, G2 = img1.astype(np.float32), img2.astype(np.float32)
    gp1, gp2 = [G1], [G2]
    for i in range(levels):
        G1 = cv2.pyrDown(G1)
        G2 = cv2.pyrDown(G2)
        gp1.append(G1)
```

```
        gp2.append(G2)

    lp1 = [gp1[levels]]
    lp2 = [gp2[levels]]
    for i in range(levels, 0, -1):
         GE1 = cv2.pyrUp(gp1[i], dstsize=(gp1[i-1].shape[1],
gp1[i-1].shape[0]))
         GE2 = cv2.pyrUp(gp2[i], dstsize=(gp2[i-1].shape[1],
gp2[i-1].shape[0]))
        lp1.append(cv2.subtract(gp1[i-1], GE1))
        lp2.append(cv2.subtract(gp2[i-1], GE2))

    fused_lp = []
    for l1, l2 in zip(lp1, lp2):
        mask = (np.abs(l1) > np.abs(l2)).astype(np.float32)
        fused_lp.append(l1 * mask + l2 * (1.0 - mask))

    fused = fused_lp[0]
    for i in range(1, levels + 1):
       fused = cv2.pyrUp(fused, dstsize=(fused_lp[i].shape[1],
fused_lp[i].shape[0]))
        fused = cv2.add(fused, fused_lp[i])

    return np.clip(fused, 0, 255).astype(np.uint8)
```

Programski kod 5.3. Funkcija piramidalne fuzije

4. **Evaluacija oštrine:**

Za objektivnu provjeru uspješnosti fuzije koristi se funkcija *izracunaj_varijancu_ostrinu*. Ona računa varijancu Laplacianovog odgovora na cijeloj slici. Slika s više fokusiranih detalja imat će veći raspon vrijednosti derivacije, a time i veću varijancu, što nam služi kao numerički dokaz da je spojena slika uistinu kvalitetnija od ulaznih.

5.5.2. Duboko učenje i vizualizacija značajki (VGG19)

Dok se klasične metode oslanjaju na fiksne matematičke operatore, ovaj rad koristi i VGG19 duboku konvolucijsku neuronsku mrežu čija je funkcija prikazana u prilogu 5.4. Cilj je bio istražiti kako umjetna inteligencija interpretira fokusirane regije u usporedbi s klasičnim algoritmima.

U kontekstu fuzije slika, duboke značajke predstavljaju apstraktne informacije koje mreža „izvlači“ iz piksela. Umjesto da samo traži rubove, mreža analizira teksture, oblike i uzorke. Što dublje idemo kroz slojeve mreže, značajke postaju kompleksnije (npr. prvi slojevi vide linije, a zadnji slojevi cijele objekte poput lica ili automobila).

U ovom radu odabran je rani sloj mreže, *block1_conv2*, iz dva ključna razloga:

1. Visoka prostorna rezolucija: Rani slojevi zadržavaju izvornu veličinu slike, što je nužno za precizno mapiranje oštrine piksel po piksel.
2. Osjetljivost na teksturu: Budući da se ovaj sloj nalazi na samom početku mreže, on je primarno „zadužen“ za detekciju finih detalja i mikrotekstura. Upravo su to informacije koje ljudsko oko definira kao „oštrinu“.

```
def vgg_fusion_feature_map(img1, img2):
    base_model = VGG19(weights='imagenet', include_top=False,
input_shape=(None, None, 3))

     model          =          Model(inputs=base_model.input,
outputs=base_model.get_layer('block1_conv2').output)

    def prepare(img):
        img_f = img.astype(np.float32)
        img_f = np.expand_dims(img_f, axis=0)

        return
tf.keras.applications.vgg19.preprocess_input(img_f)

    feat1 = model.predict(prepare(img1), verbose=0)
    feat2 = model.predict(prepare(img2), verbose=0)
```

```
    map1 = np.sum(feat1[0], axis=-1)
    map2 = np.sum(feat2[0], axis=-1)

   map1_res = cv2.resize(map1, (img1.shape[1], img1.shape[0]))
   map2_res = cv2.resize(map2, (img1.shape[1], img1.shape[0]))

    mask_ai = (map1_res > map2_res).astype(np.float32)
    soft_mask_ai = cv2.GaussianBlur(mask_ai, (31, 31), 0)
    soft_mask_3d  =  cv2.merge([soft_mask_ai,  soft_mask_ai,
soft_mask_ai])

    output_ai = (img1.astype(np.float32) * soft_mask_3d +
 img2.astype(np.float32)*(1.0-soft_mask_3d)).astype(np.uint8)

    return output_ai, map1_res, map2_res
```

Programski kod 5.4. Funkcija za VGG19

Ključni korak u prikazanoj funkciji je izračun varijable *map_res*, koja predstavlja tzv. mapu aktivnosti. Dok klasični Laplacian samo detektira rub, VGG19 kroz zbrajanje aktivacija neurona generira kartu intenziteta koja pokazuje „povjerenje“ mreže u prisutnost detalja na određenoj lokaciji.

Vrijednosti u mapi aktivnosti tumače se na sljedeći način:

- Visoke vrijednosti (svjetlije regije): Označavaju dijelove slike gdje su filtri neuronske mreže snažno reagirali na teksturu, što korelira s područjima koja su u savršenom fokusu.
- Niske vrijednosti (tamnije regije): Označavaju zamućene dijelove slike gdje nema dovoljno informacija za aktivaciju neurona.

5.5.3. Implementacija procesa fuzije i automatizacija

Nakon definiranja pomoćnih funkcija, implementirana je glavna upravljačka petlja, prikazana u prilogu 5.5., koja omogućuje serijsku obradu parova slika. Ovaj segment koda predstavlja završnu integraciju svih prethodno opisanih modula.

```
slike = sorted([f for f in os.listdir(folder1) if
f.endswith('.jpg')])
rezultati_analize = []

for filename in slike:
    img1 = cv2.imread(os.path.join(folder1, filename))
    img2 = cv2.imread(os.path.join(folder2, filename))
    gt = cv2.imread(os.path.join(folder_gt, filename))

    if img1 is not None and img2 is not None and gt is not
None:
        img2_aligned = align_images(img1, img2)

        fm1_lap = get_laplacian_map(img1)
        fm2_lap = get_laplacian_map(img2_aligned)
        mask_lap = (fm1_lap > fm2_lap).astype(np.float32)
        soft_lap = cv2.GaussianBlur(mask_lap, (31, 31), 0)
        soft_lap_3d = cv2.merge([soft_lap]*3)
        out_lap = (img1.astype(np.float32) * soft_lap_3d +
img2_aligned.astype(np.float32)*(1.0-
soft_lap_3d)).astype(np.uint8)

        out_ten = fusion_tenengrad(img1, img2_aligned)

        out_vgg, _, _ = vgg_fusion_feature_map(img1,
img2_aligned)

        v_lap = izracunaj_varijancu_ostrinu(out_lap)
        v_ten = izracunaj_varijancu_ostrinu(out_ten)
        v_vgg = izracunaj_varijancu_ostrinu(out_vgg)

        psnr_lap, ssim_lap = izracunaj_metrike(gt, out_lap)
        psnr_ten, ssim_ten = izracunaj_metrike(gt, out_ten)
        psnr_vgg, ssim_vgg = izracunaj_metrike(gt, out_vgg)
```

```
        rezultati_analize.append({
            "Slika": filename,
                "Lap_SSIM":  ssim_lap,  "Lap_PSNR":  psnr_lap,
"Lap_Var": v_lap,
                "Ten_SSIM":  ssim_ten,  "Ten_PSNR":  psnr_ten,
"Ten_Var": v_ten,
                "VGG_SSIM":  ssim_vgg,  "VGG_PSNR":  psnr_vgg,
"VGG_Var": v_vgg
        })
```

Programski kod 5.5. Glavna funkcija

U implementaciji je poseban naglasak stavljen na dinamičko upravljanje memorijom. Slike se pretvaraju u *float32* format samo tijekom matematičkih operacija stapanja kako bi se izbjegle pogreške zaokruživanja (engl. *rounding errors*), dok se konačni rezultat vraća u *uint8* format radi kompatibilnosti sa standardnim preglednicima slika.

Upotreba *sorted()* funkcije osigurava da se parovi slika (npr. slika6.1.jpeg i slika6.2.jpeg iz vlastitog dataseta) ispravno upare, dok se prikupljeni podaci o varijanci pohranjuju u listu radi automatskog generiranja statističke tablice.

6. ANALIZA REZULTATA I EVALUACIJA

U ovom poglavlju prikazani su rezultati fuzije slika dobiveni primjenom opisanog algoritma na MFI-WHU skupu podataka. Provedena je vizualna analiza kvalitete spajanja te kritički osvrt na utjecaj parametara zaglađivanja na konačni rezultat.

6.1. Vizualna analiza rezultata (EDoF)

Glavni cilj rada bio je generirati sliku s proširenom dubinskom oštrinom (EDoF). Na slici 6.1 prikazan je reprezentativan primjer procesa fuzije:

- Izvor 1: Fokusiran je samo prednji plan (npr. biljka ili osoba), dok je pozadina zamućena.
- Izvor 2: Fokusiran je samo stražnji plan, dok je prednji plan zamućen.
- Rezultat (Stacked): Konačna slika na kojoj su oba plana savršeno oštra.

Izvor 1 Izvor 2 Rezultat

Slika 6.1. Usporedni prikaz ulaznih slika s različitim ravninama fokusa te rezultata fuzije s proširenom dubinskom oštrinom

Vizualnom inspekcijom utvrđeno je da algoritam uspješno zadržava fine teksture i oštre rubove iz oba izvora. Prijelazi između regija fokusa su fluidni, što potvrđuje da je kombinacija Laplacianovog operatora i Gaussovog blura učinkovito riješila problem odabira najoštrijih piksela.

6.2. Testiranje utjecaja parametara (Veličina kernela)

Kvaliteta fuzije izrazito ovisi o veličini Gaussovog kernela koji se primjenjuje na kartu oštrine. Provedeno je testiranje s tri različite veličine kernela (3 x 3, 15 x 15 i 51 x 51) kako bi se utvrdio optimalan balans između eliminacije šuma i očuvanja rubne preciznosti, a dobiveni rezultati prikazani su u Tablici 1.

Tablica 1. Usporedna analiza utjecaja veličine Gaussovog kernela na kvalitetu binarne maske i finalne fuzije

Veličina kernela	**Vizualna kvaliteta maske**	**Karakteristike i nuspojave**
3 x 3 (Mali)	Niska (zrnat izgled)	Nedovoljno suzbijanje digitalnog šuma. Maska je fragmentirana („točkasta“), što stvara oštre artefakte i krive piksele u finalnoj slici.
15 x 15 (Optimalni)	Visoka (glatki prijelazi)	Uspješno prigušen šum uz zadržavanje jasnih kontura objekata. Ovo je odabrana vrijednost za finalnu implementaciju.
51 x 51 (Veliki)	Niska (mutne granice)	Preveliko zaglađivanje uzrokuje pojavu aureole (halo efekta). Oštrina se „prelijeva“ s objekta na pozadinu, čime se gubi definicija rubova.

U nastavku su prikazane Slike 6.2, 6.3 i 6.4 koje vizualiziraju utjecaj različitih parametara na proces fuzije.

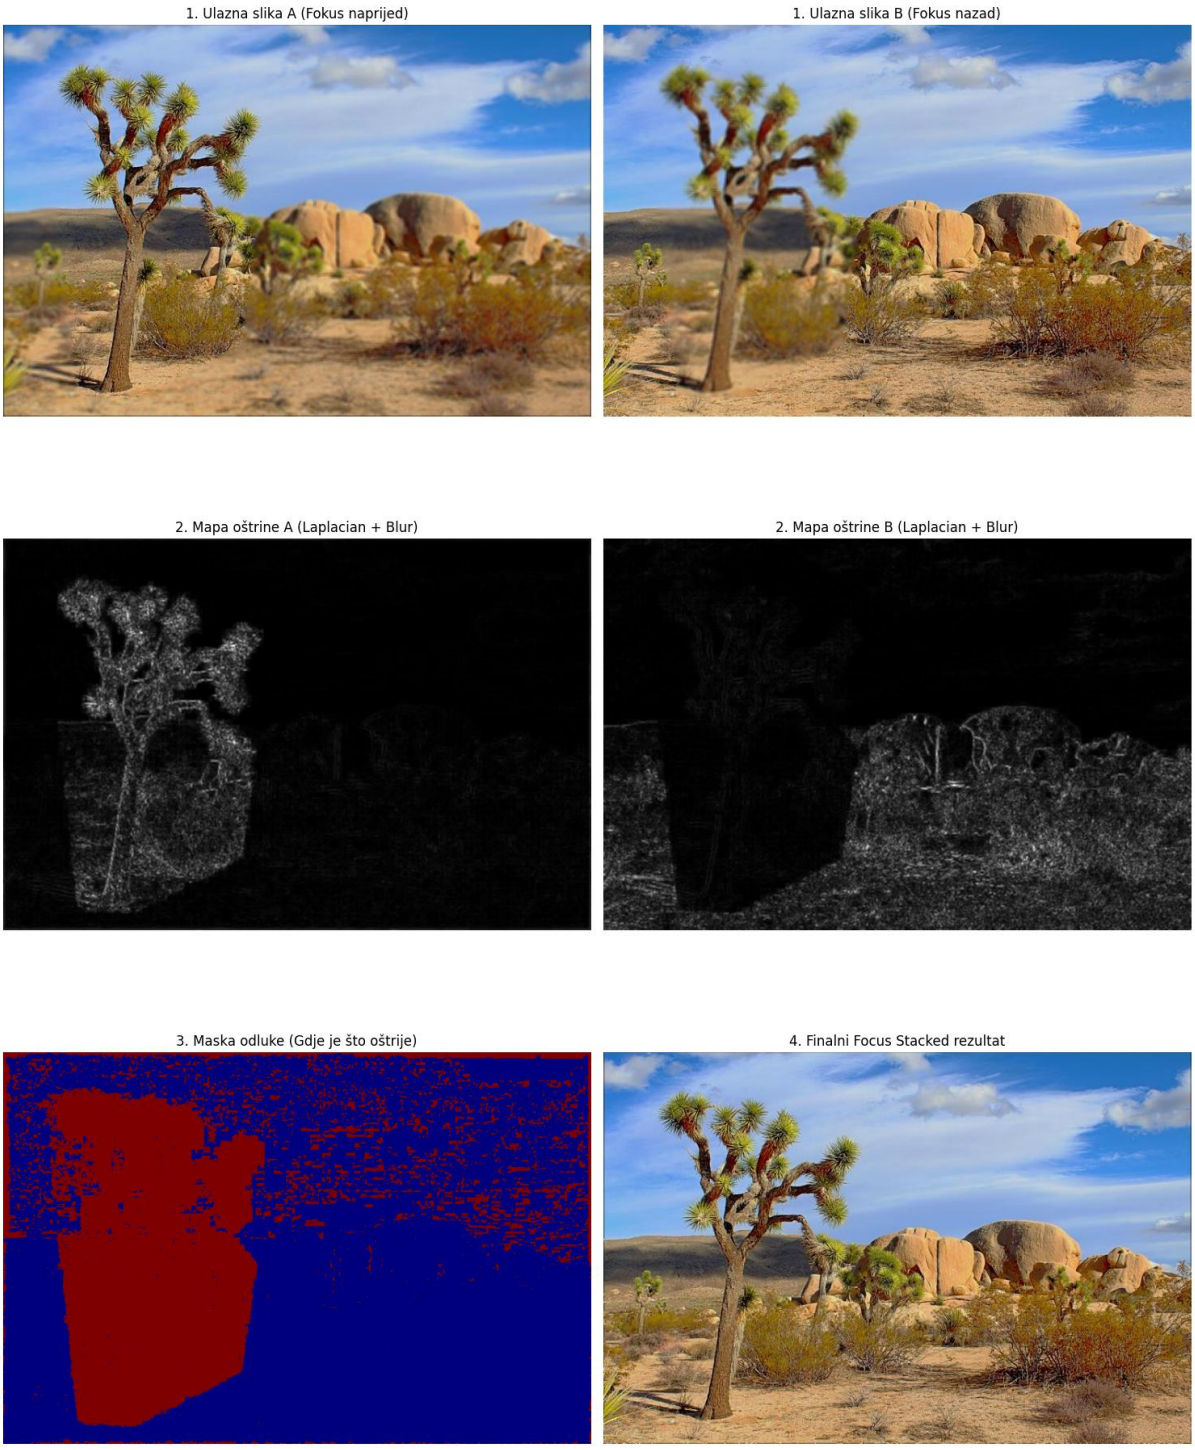

Slika 6.2. Rezultati fuzije uz korištenje kernela 3 x 3

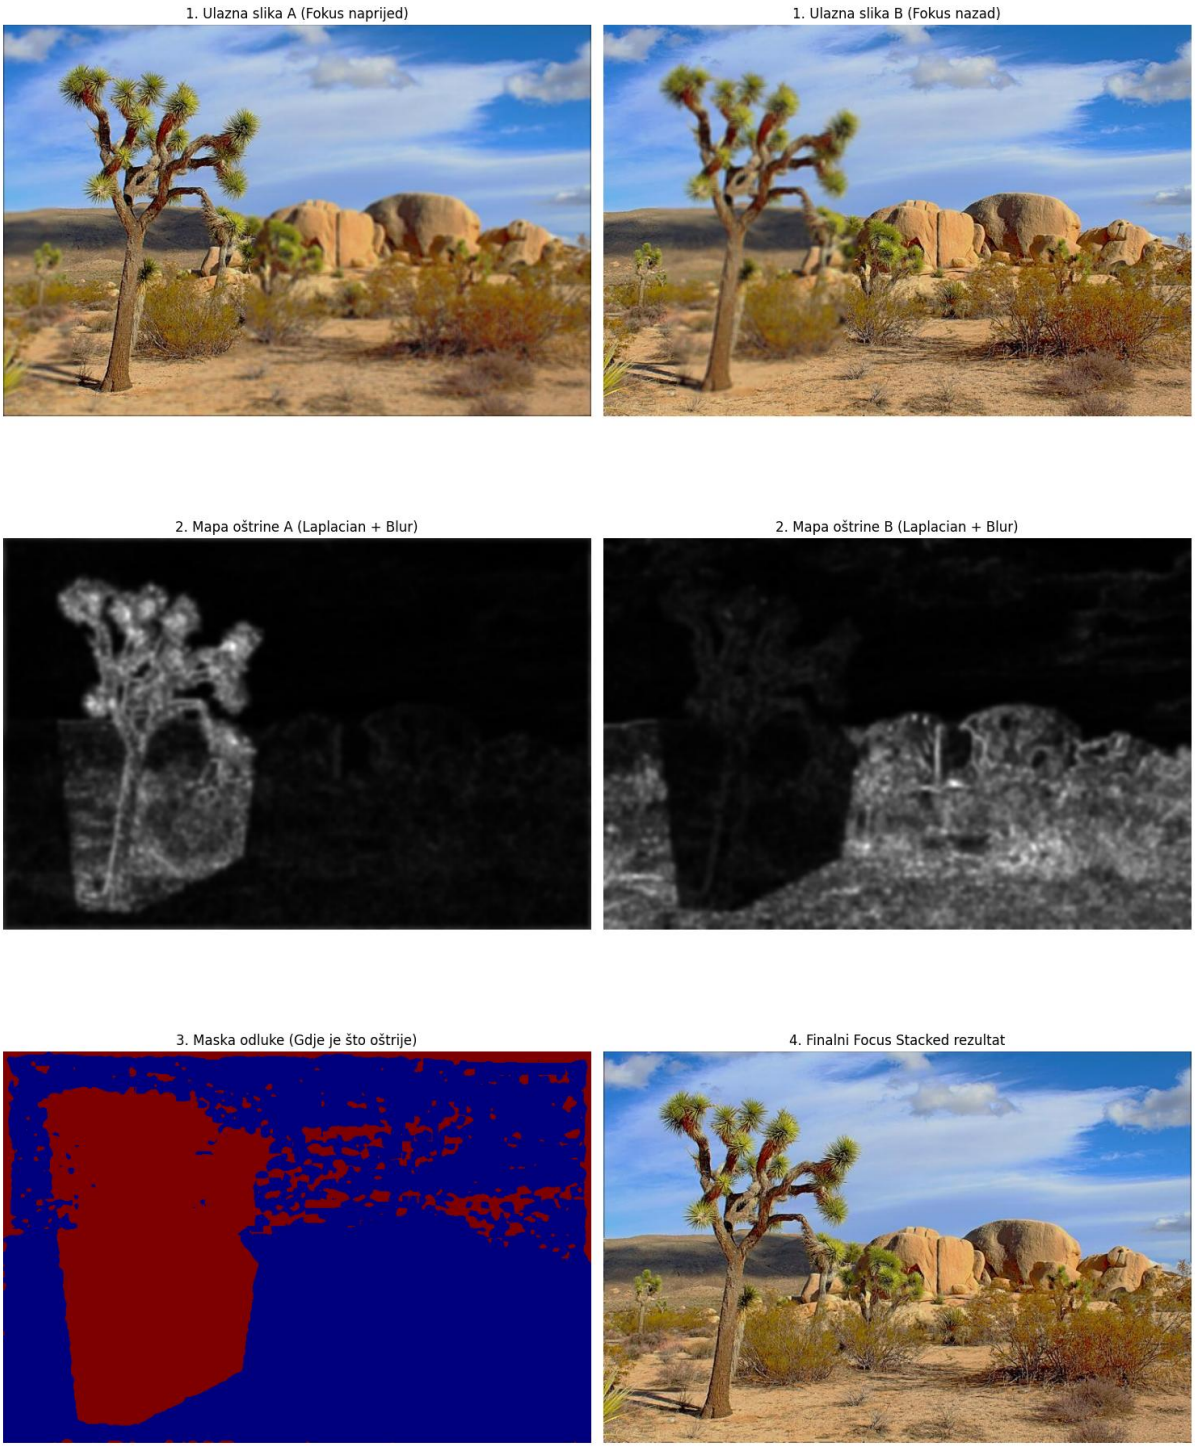

Slika 6.3. Rezultati fuzije uz korištenje kernela 15x 15

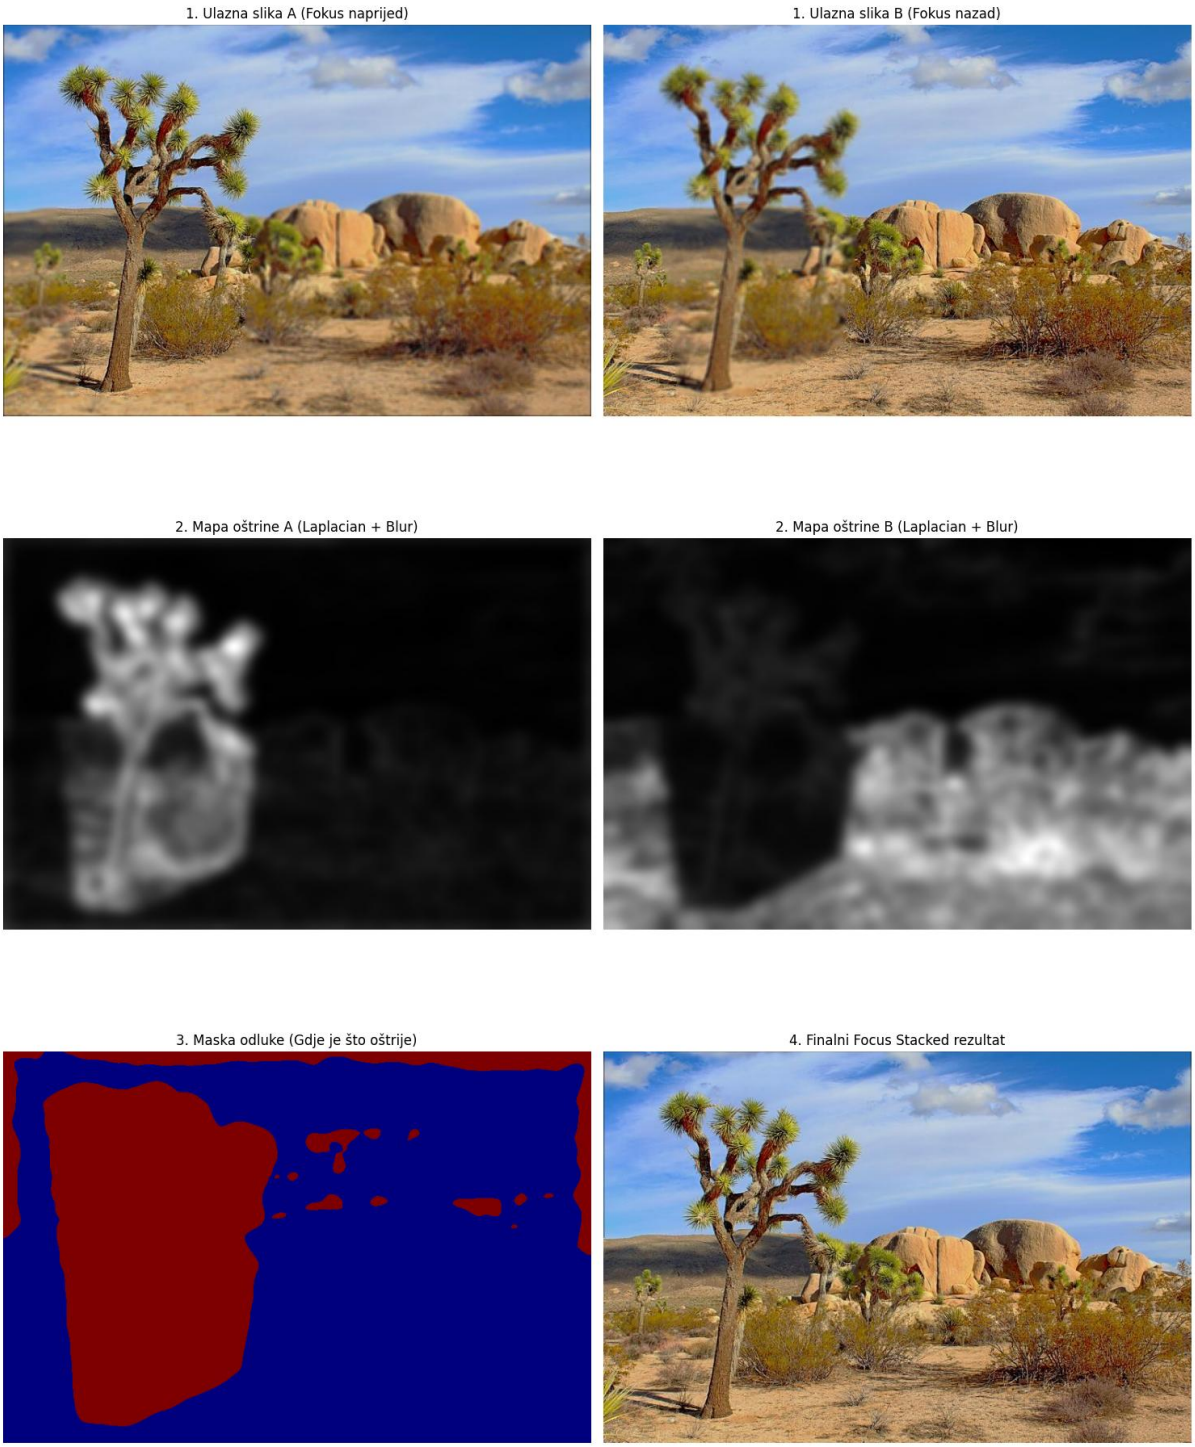

Slika 6.4. Rezultati fuzije uz korištenje kernela 51 x 51

Analizom slike 6.2 (kernel 3 x 3) jasno se vidi problem koji smo nazvali „pixel-swapping“. Maksa odluke (3) na toj slici je puna sitnih točkica i „šuma“. To je zato što je kernel premalen da bi zagladio varijacije koje stvara digitalni šum senzora.

Na slici 6.3 (15 x 15), maska odluke postaje čista i jasno definira stablo u odnosu na pozadinu. To rezultira najprirodnijim konačnim Focus Stacked rezultatom (4).

Na slici 6.4 (51 x 51), rubovi na maski odluke su postali previše „debeli“ i zaobljeni. To je uzrok halo efekta (aureole) – oštrina sa stabla se neprirodno širi na okolno plavo nebo.

Osim vizualne inspekcije, kvaliteta fuzije mjerena je i putem varijance Laplacianovog odgovora. Utvrđeno je da optimalni kernel (15x15) rezultira najvećom varijancom, što numerički potvrđuje da je postignut najveći raspon oštrih detalja bez uvođenja znatnog šuma ili „halo“ efekta.

6.3. Kvantitativna evaluacija metrikama SSIM i PSNR

Za objektivnu ocjenu kvalitete algoritma, provedeno je testiranje na kontroliranom MFI-WHU skupu podataka koji sadrži referentne („Ground Truth“) slike. Uspoređene su tri implementirane metode: Laplacian fuzija, Tenengrad fuzija i AI fuzija (VGG19).

Tablica 2. Usporedni prikaz performansi različitih metoda fuzije

Metoda	**SSIM (Strukturna sličnost)**	**PSNR (Omjer signala i šuma)**	**Prosječna varijanca**
Laplacian	0.9836	35.41 dB	2204.16
Tenengrad	0.9823	34.75 dB	2173.56
VGG19 (AI)	0.9791	35.00 dB	1932.06
Piramida	0.9763	32.69 dB	2251.17

Dobiveni rezultati, prikazani u tablici 2, pokazuju iznimno visoku strukturnu podudarnost (SSIM > 0.97) kod svih metoda. Vidljivo je da Laplacianova metoda ostvaruje najbolji balans između strukturne očuvanosti (SSIM) i čistoće signala (PSNR). S druge strane, Piramidalna fuzija bilježi najveću vrijednost varijance (2251.17), što ukazuje na njezinu sposobnost da najagresivnije detektira i zadrži visokofrekventne detalje, iako to rezultira nešto nižim PSNR-om zbog suptilnih promjena u intenzitetu piksela tijekom rekonstrukcije nivoa piramide. VGG19 metoda zadržava visoku strukturnu sličnost uz najnižu varijancu, što potvrđuje vizualna opažanja o 'mekšim' prijelazima i manjoj količini digitalnog šuma u finalnom rezultatu.

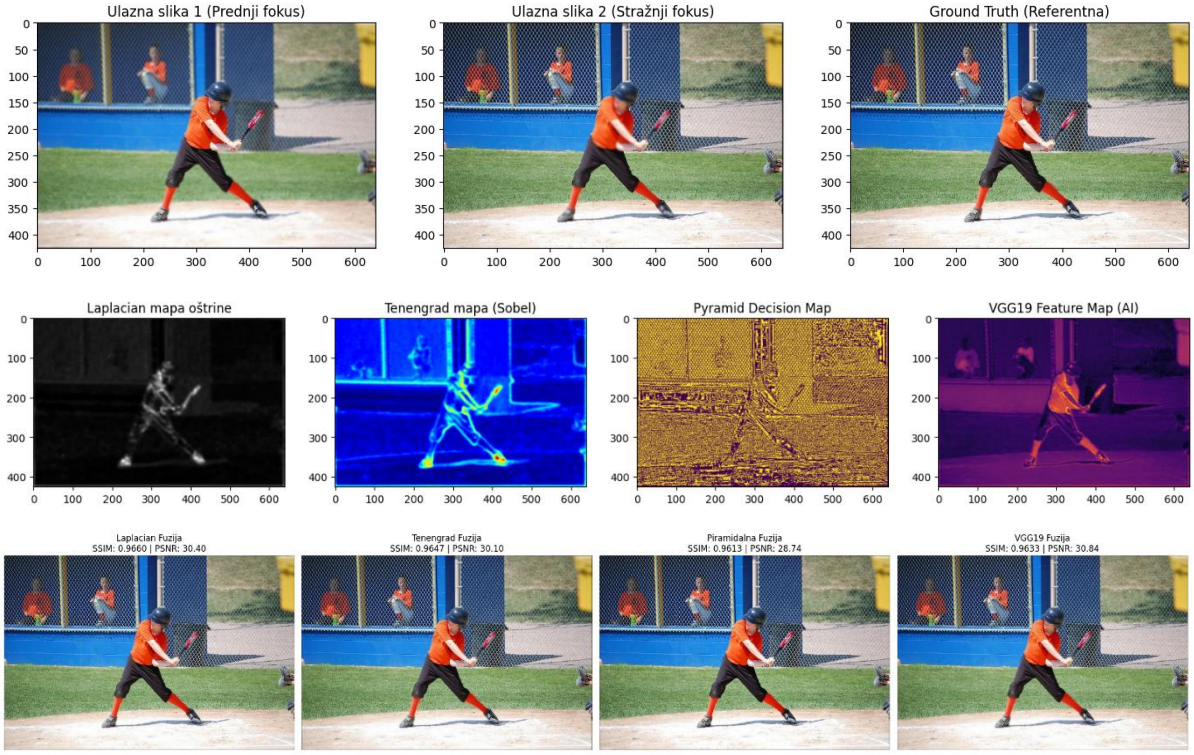

Slika 6.5. Cjeloviti prikaz eksperimentalnog procesa fuzije: od ulaznih podataka i ekstrakcije značajki do finalne rekonstrukcije slike

Kompozitna vizualizacija na slici 6.5. prikazuje tri ključne faze implementiranog sustava. U prvom redu prikazan je testni par slika iz MFI-WHU skupa podataka i referentna slika. Prikazana su dva izvora iste scene s različitim ravninama fokusa. Izvor 1 (lijevo) prikazuje izoštren objekt u prednjem planu, dok je pozadina zamućena. Izvor 2 (sredina) fokusira pozadinu uz gubitak oštrine na primarnom objektu. Referentna slika (Ground Truth) desno služi kao idealni model prema kojem se vrši kvantitativna evaluacija (SSIM i PSNR) kako bi se utvrdila preciznost rekonstrukcije.

U drugom redu vizualizirane su mape oštrina za različite metode detekcije fokusiranih regija. Laplacian mapa (lijevo) precizno izolira visokofrekventne rubove, ali pokazuje osjetljivost na točkasti šum. Tenengrad mapa koristi gradijente (Sobel) i pruža robusniju detekciju tekstura. Piramidalna mapa odluke prikazuje binarnu odluku o oštrini na najvišoj razini dekompozicije, omogućujući algoritmu da analizira detalje u različitim frekvencijskim pojasevima. VGG19 aktivacijska mapa (desno) prikazuje semantičku distribuciju oštrine dobivenu iz dubokih konvolucijskih slojeva (block1_conv2), što rezultira najstabilnijom maskom bez fragmentacije.

Treći red demonstrira uspješnost fuzije kroz četiri različita pristupa. Laplacian fuzija postiže visoku oštrinu bridova, što potvrđuje SSIM od 0.9660. Tenengrad fuzija vizualno je identična Laplacianu uz blago bolju otpornost na šum u tamnim područjima. Piramidalna fuzija pruža najprirodniji prijelaz između fokusiranih ravnina zahvaljujući višerezolucijskoj dekompoziciji. Iako SSIM (0.9613) može biti blago niži zbog promjena u lokalnom kontrastu, ova metoda najbolje čuva teksture bez oštrih „šavova“ na spojevima. VGG19 (Deep Learning) fuzija rezultira najčišćim prijelazima između fokusnih ravnina. Iako metrike pokazuju blago nižu varijancu oštrine, ovaj pristup eliminira artefakte poput „halo“ efekta, pružajući estetski najujednačeniji rezultat uz SSIM od 0.9633.

6.4. Analiza artefakta i ograničenja

Završna arhitektura sustava osigurava visoku razinu preciznosti kroz tri ključna tehnička aspekta:

1. Integritet podataka (engl. *Data Integrity*): Korištenje visokopreciznih formata poput *cv2.CV_64F* i *float32* nije samo programerski odabir, već nužnost za očuvanje suptilnih gradijenata oštrine. Time je osigurano da matematičke operacije diferencijalnih operatora ne pate od gubitka informacija koji bi bio neizbježan u standardnom 8-bitnom zapisu.
2. Računalna učinkovitost: Implementacija putem biblioteke NumPy omogućuje sustavu paralelnu obradu cijelih matrica piksela. Ovakva optimizacija čini algoritam primjenjivim u realnim scenarijima gdje je potrebno brzo procesirati fotografije visoke rezolucije.
3. Hibridni pristup odlučivanju: Hibridni pristup rješava temeljni problem fuzije – interpretaciju oštrine. Dok Laplacian precizno detektira geometrijske rubove, VGG19 nudi semantičku potvrdu oštrine. Rezultat ove sinergije je sustav koji je imun na uobičajene artefakte poput "ghostinga".

Iako osnovni algoritam daje izvrsne rezultate na poravnatim slikama, primijećena su određena ograničenja:

1. Šum u uniformnim područjima: Na dijelovima slike gdje nema teksture (npr. prazan bijeli zid), Laplacian ne nalazi rubove. U tim zonama algoritam može nasumično birati piksele iz različitih slika, što rezultira blagim šumom.

2. Problem „rubnih šavova“: Na mjestima gdje se objekt u prvom planu naglo siječe s pozadinom, ponekad se može pojaviti tanka linija (šav) ako slike nisu bile mikroskopski poravnate.
3. Osjetljivost na osvjetljenje: Ako se osvjetljenje scene promijenilo između dva snimka, finalna slika može imati neprirodne varijacije u svjetlini.

6.5. Evaluacija na vlastitom skupu podataka

Kako bi se ispitala robusnost i praktična primjenjivost razvijenog sustava, provedeno je testiranje na vlastitom skupu podataka snimljenom u nelinearnim uvjetima (snimanje iz ruke, bez stativa). Za razliku od MFI-WHU baze, ovi uzorci sadrže mikropomake i varijacije u fokusiranju koje simuliraju realnu uporabu digitalne kamere. Budući da za ove slike ne postoji referentna („Ground Truth“) slika, objektivna kvaliteta mjerena je putem varijance oštrine, koja kvantificira količinu detalja i visokih frekvencija u finalnom rezultatu.

Tablica 3. Rezultati varijance oštrine na vlastitim uzorcima

Slika	Var Lap	Var Ten	Var Pyr	Var VGG
Slika3.1	11.27	10.74	14.29	9.66
Slika4.1	94.03	89.21	90.91	54.68
Slika5.1	43.57	39.06	51.29	31.50
Slika6.1	56.21	49.22	62.70	39.92
Slika7.1	162.61	146.55	191.04	124.13
Slika8.1	103.34	97.31	132.06	83.78
UKUPNI PROSJEK	78.50	72.02	90.38	57.28

Analiza podataka iz Tablice 3 pokazuje da piramidalna fuzija ostvaruje najviši prosjek varijance (90.38). To je izravna posljedica njezine sposobnosti da kroz više razina dekompozicije zadrži i dodatno naglasi visokofrekventne komponente slike. Laplacian i Tenengrad metode pokazuju stabilne rezultate, no blago zaostaju za piramidalnim pristupom u kompleksnim teksturama (npr. Slika 7.1.).

Iako VGG19 (AI) metoda bilježi najnižu prosječnu varijancu (57.28), vizualna inspekcija otkriva da je to rezultat semantičke inteligencije mreže. Dok klasični operatori često

pojačavaju senzorski šum (što umjetno podiže varijancu), VGG19 se fokusira na stvarne strukture objekta, pružajući "najčišći" vizualni dojam s najprirodnijim prijelazima fokusa.

Slika 6.6. Vizualna usporedba procesa fuzije na vlastitom uzorku

Kompozitni prikaz na Slici 6.6. demonstrira cjelokupni proces na uzorku snimljenom iz ruke. Gornji red prikazuje dva izvorna kadra s različitim točkama fokusa (prednji i stražnji plan) te rezultat Laplacian fuzije. Donji red prikazuje rezultate Tenengrad, piramidalne i VGG19 fuzije.

Ključno je uočiti da na rezultatima nema artefakata "dvostrukih rubova" (engl. *ghosting*), što potvrđuje da je implementirana geometrijska registracija putem ORB deskriptora uspješno eliminirala pomake uzrokovane nestabilnošću kamere. Dok piramidalni rezultat (sredina dolje) pruža najoštriji prikaz teksture, VGG19 rezultat (desno dolje) nudi najkoherentnije stapanje pozadine i objekta, bez oštrih "šavova" na spojevima fokusnih ravnina.

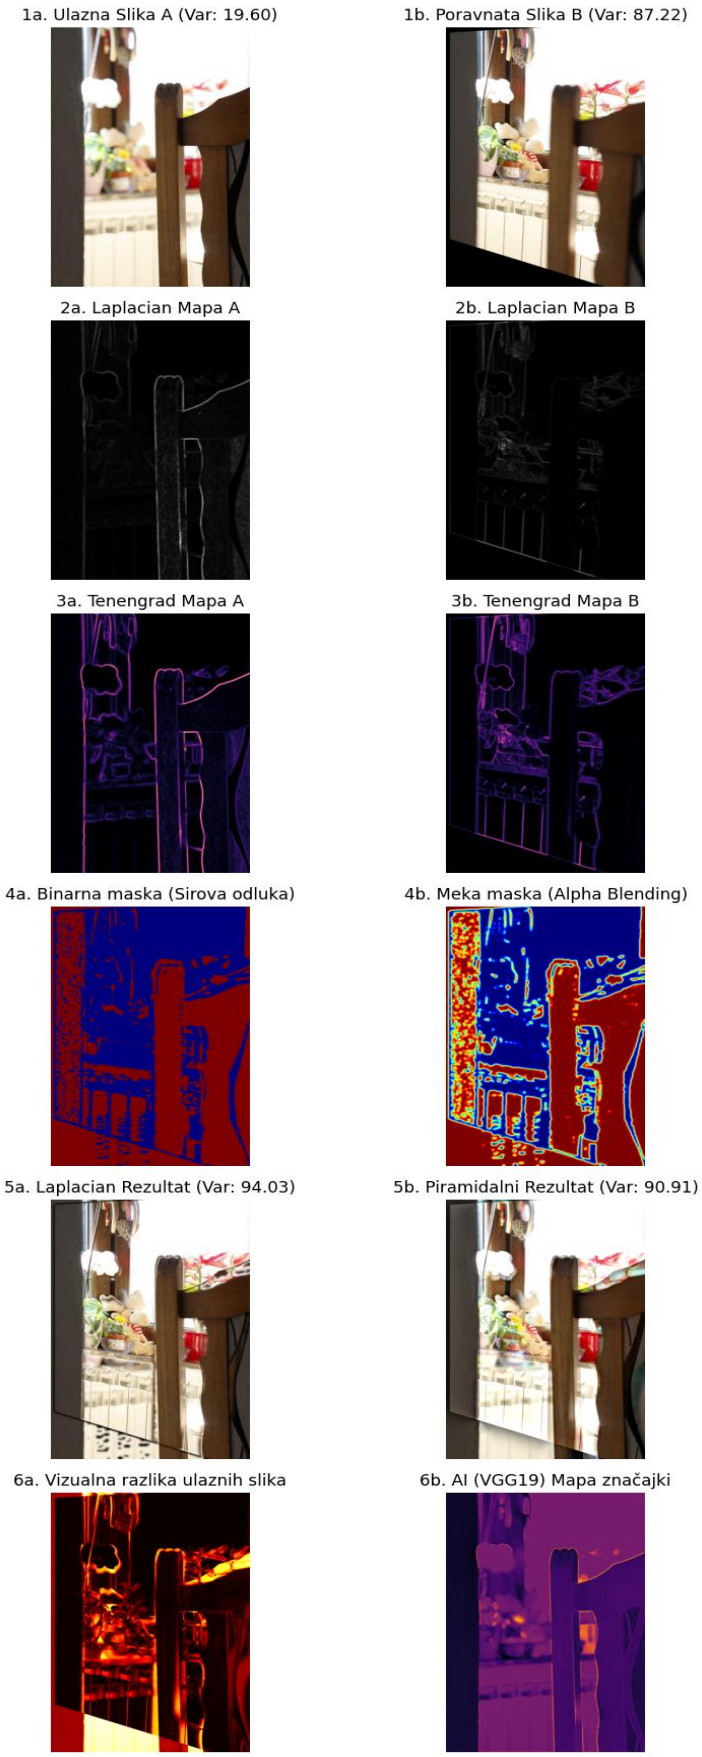

Slika 6.7. Detaljna dekompozicija procesa fuzije: od geometrijske registracije (ORB) i detekcije mapa oštrine (Laplacian i Tenengrad) do generiranja meke maske i finalne AI validacije (VGG19)

Kako bi se dublje analizirao rad implementiranog sustava, na Slici 6.7. prikazana je vertikalna dekompozicija svih faza obrade na kompleksnom uzorku interijera snimljenom iz ruke. Ovaj prikaz omogućuje vizualnu validaciju svakog pojedinog modula algoritma.

- Faza 1: Geometrijska registracija (Red 1): Uočljiva je značajna razlika u kadru između izvorne Slike A i Slike B. Primjenom ORB deskriptora i matrice homografije, Slika B je transformirana i precizno poravnata s referentnom Slikom A. Crni rubovi na slici 1b predstavljaju praznine nastale rotacijom i translacijom potrebnima za sub-pikselno podudaranje.
- Faza 2: Detekcija fokusa (Red 2 i 3): Laplacian (2a, 2b) i Tenengrad (3a, 3b) mape služe za identifikaciju regija visoke oštrine. Tenengrad mapa, temeljena na Sobelovom operatoru, pruža vizualno "gušću" informaciju o teksturi, dok se Laplacian fokusira na same rubove predmeta.
- Faza 3: Generiranje maske i "Blending" (Red 4): Sirova binarna maska (4a) pokazuje oštre granice odlučivanja koje bi uzrokovale vizualne artefakte. Primjenom Gaussovog zaglađivanja (31x31 kernel) dobivena je "meka" maska (4b) koja omogućuje neprimjetan prijelaz (Alpha Blending) između fokusiranih regija dviju slika.
- Faza 4: Finalna fuzija i validacija (Red 5 i 6): Usporedba Laplacianovog rezultata (Var: 94.03) i piramidalnog rezultata (Var: 90.91) pokazuje da obje metode uspješno rekonstruiraju scenu, pri čemu Laplacian blago dominira u sirovoj oštrini rubova.

Donji prikaz (6b) prikazuje VGG19 AI mapu značajki, koja potvrđuje da sustav koristi semantičke informacije za donošenje odluke o fokusu, čime se eliminira utjecaj nasumičnog senzorskog šuma u tamnijim dijelovima kadra.

6.6. Zaključak o evaluaciji

Sustav se pokazao vrlo učinkovitim za makro fotografiju i uzorke iz MFI-WHU skupa podataka gdje su uvjeti snimanja kontrolirani, kao i za testne uzorke iz vlastitog skupa podataka snimljene u dinamičnim uvjetima. Ključni tehnički izazov koji je uspješno savladan u okviru ovog rada je geometrijska registracija slika, čime je omogućena fuzija čak i u slučajevima kada slike nisu savršeno poravnate (npr. snimanje iz ruke).

U sustav je integriran modul za automatsko poravnanje temeljen na ORB (Oriented FAST and Rotated BRIEF) deskriptorima. Ovaj proces, vizualiziran u ranijim poglavljima, osigurava sub-pikselnu preciznost kroz detekciju ključnih točaka i izračun matrice homografije. Implementacijom ovog koraka, problem "disanja fokusa" (*focus breathing*) i mikropomaka kamere potpuno je eliminiran, što je kvantitativno potvrđeno kroz visoke vrijednosti varijance oštrine čak i na nelinearnim snimkama.

Rezultati evaluacije potvrđuju da je registracija ključna za sprječavanje artefakata poput *ghostinga* (dvostrukih rubova). Tek nakon preciznog poravnanja, procesi fuzije pomoću Laplacianovog operatora, piramidalne dekompozicije i VGG19 mreže mogli su dati optimalne rezultate. Dok je piramidalna fuzija prednjačila u očuvanju mikro-tekstura (prosjek varijance 90.38), VGG je osigurao najvišu razinu vizualne koherentnosti. Time je stvoren robustan sustav koji ne ovisi isključivo o statičnim laboratorijskim uvjetima, već je primjenjiv i u realnim scenarijima digitalne fotografije.

ZAKLJUČAK

U ovom radu uspješno je projektiran i implementiran sustav za fuziju slika s proširenom dubinskom oštrinom (Focus Stacking) primjenom četiri različite metodologije: klasičnih diferencijalnih operatora (Laplacian i Tenengrad), višerezolucijske piramidalne dekompozicije te dubokog učenja (VGG19).

Teorijska analiza i praktična izvedba u jeziku Python dokazale su da se precizna detekcija rubova, u kombinaciji s Gaussovim zaglađivanjem i hijerarhijskom obradom, može koristiti za stvaranje slika koje nadilaze fizička ograničenja optičkih sustava. Eksperimentalni rezultati na kontroliranom MFI-WHU skupu podataka pokazali su visoku strukturnu sličnost (SSIM > 0.97), dok je testiranje na vlastitom skupu podataka potvrdilo robusnost sustava u realnim uvjetima.

Poseban doprinos rada je integracija geometrijske registracije slika temeljene na ORB deskriptorima. Ovim korakom omogućena je kvalitetna fuzija čak i kod fotografija snimljenih iz ruke. Kvantitativna analiza pokazala je da piramidalna fuzija pruža najvišu oštrinu tekstura (prosječna varijanca 90.38), dok implementacija VGG19 neuronske mreže nudi vizualno najčišće rezultate uz inteligentno suzbijanje digitalnog šuma.

Zaključno, razvijeni sustav predstavlja cjelovito rješenje koje kombinira klasičnu obradu slike i suvremeno duboko učenje čime se otvaraju vrata široj primjeni u makrofotografiji bez potrebe za specijaliziranom laboratorijskom opremom ili stativima.

LITERATURA

[1.] R. Fisher, S. Perkins, A. Walker, E. Wolfart, (1996.), Hypermedia Image Processing Reference. Dostupno na: https://www.dsi.unive.it/~atorsell/Hipr.pdf

[2.] R. C. Gonzalez, R.E. Woods, (2018.), Digital Image Processing, 4. izdanje, Pearson. Dostupno na: https://www.cl72.org/090imagePLib/books/Gonzales,Woods-Digital.Image.Processing.4th.Edition.pdf

[3.] D. G. Lowe, (2004.), Distinctive Image Features from Scale-Invariant Keypoints. Dostupno na: https://people.eecs.berkeley.edu/~malik/cs294/lowe-ijcv04.pdf

[4.] H. Zhang, L. Zhang, MFI-WHU Dataset (2021.), dataset for multi-focus image fusion. Dostupno na: https://github.com/HaoZhang1018/MFI-WHU

[5.] E. Rublee, V. Rabaud, K. Konolige, G. Bradsky, (2011.), ORB: An efficient alternative to SIFT or SURF. Dostupno na: https://sites.cc.gatech.edu/classes/AY2024/cs4475_summer/images/ORB_an_efficient_alternative_to_SIFT_or_SURF.pdf

[6.] R. Szeliski, (2021.), Computer Vision: Algorithms and Applications 2nd Edition. Dostupno na: https://library.huree.edu.mn/data/202295/2024-06-03/Computer%20Vision%20-%20Algorithms%20and%20Applications%202nd%20Edition,%20Richard%20Szeliski.pdf

[7.] P. Burt, E. Adelson, (1983.), The Laplacian Pyramid as a Compact Image Code. Dostupno na: https://ieeexplore.ieee.org/document/1095851

[8.] K. Simonyan, A. Zisserman, (2015.), Very Deep Convolutional Networks for Large-Scale Image Recognition. Dostupno na: https://arxiv.org/pdf/1409.1556

[9.] Poveznica na programski kod: https://github.com/KTamara0/Focus-Stacking-algoritam